

Roberto Vega Sainz

ITSCC

Ing. Sistemas COmputacionales

Investigacion para el Pre tratamiento de datostípicos

Antes de poder tratar datos se tienen que tener en consideración, conocer o identificar los sig. Valores atípicos, valores nulos y los datos categóricos de modo que aseguremos que los datos recolectados sean coherentes ya que en caso contrario tratar datos defectuosos sería contraproducente.

Para ello se usará de ejemplo un archivo .csv compartido por el docente para su análisis y usarlo como ejemplo de este proceso.

Dicho archivo contiene datos sobre personas en específico donde se exponen los campos de Edad, Ingresos, Hijos, Género, Ciudad y nivel de educación.

Valores Atípicos(Outliers)

Un valor atípico también llamado observación atípica es un valor que dista mucho del resto del conjunto de datos, de modo que un valor atípico es un valor anormal extremadamente diferente al resto.

Dentro del archivo se pueden observar una multitud de estos datos en los campos:

Edad: Donde se pueden observar valores como 177.193 o incluso valores negativos siendo estos imposibles físicamente. Ya que ninguna edad puede ser superior a 120 a menos que el sujeto sea excepcional de algún modo y es directamente imposible que un ser humano tenga una edad menor a 0.

Ingresos: Dentro de los campos de ingresos aunque no imposibles distan mucho del resto de los datos por su gran tamaño algunos de estos siendo 195471 o 188965 que aunque no imposibles estos podrían ser outliers por su enorme diferencia con el resto. Además también hay valores negativos que van en contra del término de ingresos.

Hijos: hay valores negativos o fraccionarios siendo esto imposible no se puede tener una cantidad negativa de hijos o hijos a medias.

Valores Nulos

Estas son celdas vacías o sin dato que pueden ser o no problemáticas dependiendo de su categoría en este caso dentro del archivo se presentan 2.

Género: muchas filas tienen este campo vacío algo imposible

Ciudad: vacías en muchas filas

En este caso estos campos nulos deben ser rellenados o eliminados para asegurar la consistencia de los datos ya sea por moda o la media.

Datos Categoricos

Son valores que representan categorias no numeros como:

Genero: siendo categorico nominal representado con F o M

Cludad: siendo categorico nominal con ciudades como phoenix, new york o chicago

Nivel de educacion: es de tipo categorico ordinal con categorias como none, bachelors, master, PhD